

Recuperação de Informação: Apresentação da Disciplina e Conceitos Básicos

Prof. Luciano Barbosa (Material adaptado dos slides dos livros adotados)







- Objetivos:
 - Aprender principais técnicas da área de RI
 - E como engenhos de busca são construídos
- Foco na prática
 - Em universidades no exterior: dada em 3 meses com aulas teóricas de 1h



- Information Retrieval in Practice. B. Croft, D. Metzler, T. Strohman. Pearson Education, 2009.
- Introduction to Information Retrieval. C.D. Manning, P. Raghavan, H. Schuumltze. Cambridge UP, 2008.
- Modern Information Retrieval. R. Baeza-Yates, B. Ribeiro-Neto.
 ACM Press Books, 2011.

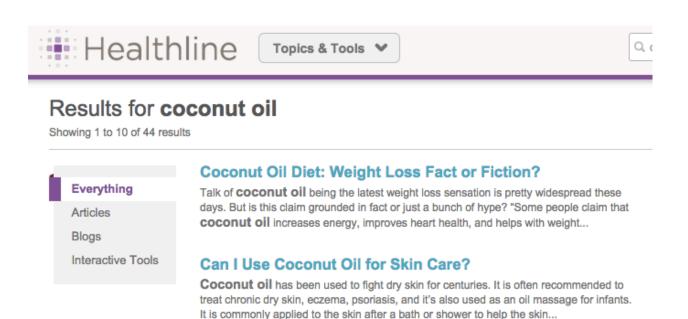
Avaliação

- Três partes
 - Projeto (60%)
 - Quiz (30%)
 - Participação (10%)
 - Obs.: Sem laptop ou celular!
- Projeto: engenho de busca vertical
 - Busca em páginas em um mesmo domínio
 - Página com "estrutura"
 - Ex:
 - Produtos (câmera, alimentos, carros etc)
 - Filmes, músicas, emprego etc









Can I Use Coconut Oil for Hair Growth?

Coconut oil is produced when the coconut meat is removed from the outer hard shell and pressed. Lately, **coconut oil** is being touted as a panacea for all sorts of ailments, from indigestion to asthma to autism. Now, some are suggesting a link between coconut...

The Health Benefits of Coconut Oil

Coconut oil is derived from the white "meat" of mature coconuts. Coconut oil is extracted by a press that separates the oil from the fruit itself.





Most Popular Titles With Quotes Matching "violence"

1-50 of 998 titles.

1. Game of Thrones (2011 TV Series)

Episode: A Man Without Honor (2012)

Have you gone soft, Clegane? I always thought you had a talent for violence. Burn the villages, burn the farms. Let them know what it means to choose the wrong side.

2. Game of Thrones (2011 TV Series)

Episode: The Broken Man (2016)

Violence is a disease. You don't cure a disease by spreading it to more people.

Game of Thrones (2011 TV Series)

Episode: A Golden Crown (2011)

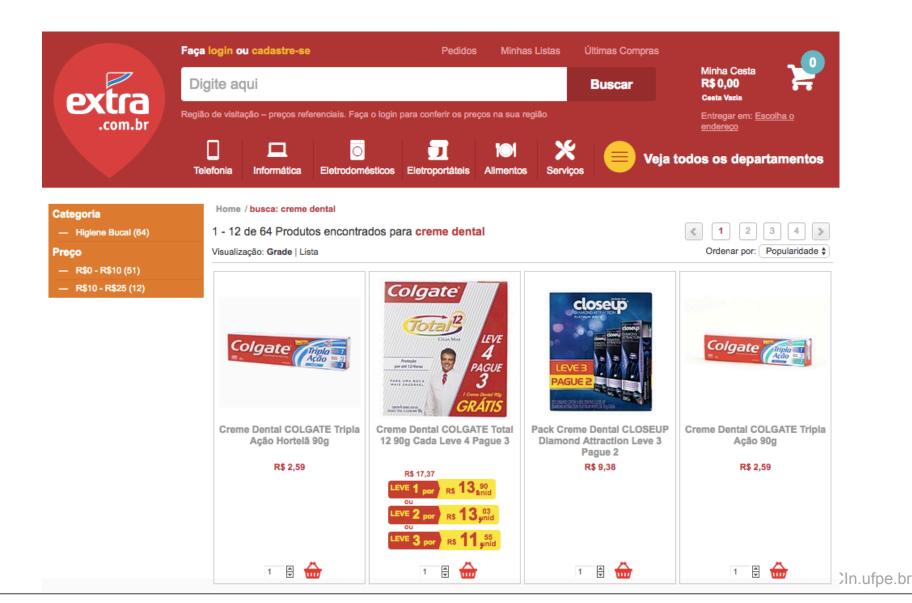
Where do I begin, my lords and ladies? I am a vile man, I confess it. My crimes and sins are beyond counting. I have lied and cheated, gambled and whored. I'm not particularly good at violence, but I'm good at convincing others to do violence for me. You want specifics, I suppose. When I was seven, I saw a servant girl bathing in the river. I stole her robe and she was forced to return to the castle naked and in tears. I close my eyes, but I can still see her tits bouncing...

4. Game of Thrones (2011 TV Series)

Episode: No One (2016)

I choose violence.







Primeiro Módulo da Disciplina

- Introdução ao Curso
- Funcionamento de Engenhos de Busca
- Coleta de Dados
- Processamento de Texto
- Classificação de Texto
- Extração de Dados na Web



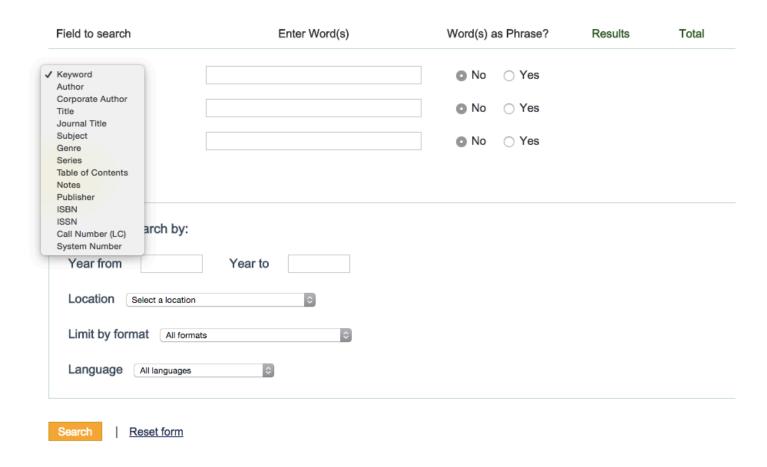
Segundo Módulo da Disciplina

- Indexação de Dados
- Busca:
 - Modelos de RI
 - Ranking e Processamento de Consultas
 - Refinamento de Consultas
 - Avaliação de Sistemas de RI
- Sistemas de recomendação
- Análise de Links



Recuperação de Informação: Origens

Buscar documentos em bibliotecas





Recuperação de Informação

- Lida com representação, armazenamento e acesso a itens de informação:
 - Documentos, páginas Web, dados estruturados, objetos multimídia
- Estruturas de dados para rápido acesso: índice

QA76 .55 .C58 1995	Clark, Michael Cultural treasures of the Internet / M. Clark Upper Saddle River, N.J.: Prentice Hall, 1995. xxix, 313 p.: ill.; 24 cm. ISBN 0132096692.					
	1. ComputersCultural Impact. 2. InternetCultural Impact.					



Objetivo de RI

- Satisfazer a necessidade de informação do usuário
- Usuário precisa "traduzir" para um conjunto de termos
- **Exemplo:**
 - "Encontrar todos os documentos sobre o Governo Federal relacionados ao financiamento dos estádios da Copa do Mundo"
- Não necessariamente uma boa estrutura de consulta
- Recuperar todos documentos relevantes e o menor número de não-relevantes



O que é um Documento?

- Exemplos: páginas Web, livros, notícias, artigos, mensagens de textos, posts, pdfs etc
- Propriedades de um documento:
 - Texto
 - Alguma estrutura



Estrutura em Documentos

Artigos: título, autor, instituição etc

Efficiently Linking Text Documents with Relevant Structured Information

Venkatesan T. Chakaravarthy Himanshu Gupta Prasan Rov Mukesh Mohania IBM India Research Lab New Delhi, India {vechakra, higupta3, prasanr, mkmukesh}@in.ibm.com

ABSTRACT

Faced with growing knowledge management needs, enterprises are increasingly realizing the importance of interlinking critical business information distributed across structured and unstructured data sources. We present a novel system, called EROCS, for linking a given text document with relevant structured data. EROCS views the structured data as a predefined set of "entities" and identifies the entities that best match the given document. EROCS also embeds the identified entities in the document, effectively creating links between the structured data and segments within the document. Unlike prior approaches, EROCS identifies such links even when the relevant entity is not explicitly mentioned in the document. EROCS uses an efficient algorithm that performs this task keeping the amount of information retrieved from the database at a minimum. Our evaluation shows that EROCS achieves high accuracy with reasonable overheads.

structured data consists of all information about sales transactions, customers and products. The organization, with a network of multiple stores, has a steady inflow of complaints into a centralized complaint repository; these complaints are accepted using alternative means, such as a web-form, email, fax and voice-mail (which is then transcripted). Each such complaint is typically a free-flow narrative text about one or more sales transactions, and is not guaranteed to contain the respective transaction identifiers; instead, it might divulge, by way of context, limited information such as the the store name, a partial list of items bought, the purchase dates, etc. Using this limited information, EROCS discovers the potential matches with the transactions present in the sales transactions database and links the given complaint with the matching transactions.

Such linkage provides actionable context to a typically fuzzy, free flow narrative which can be profitably exploited in a variety of ways.



Documentos vs. Entradas em BD: Estrutura

- Campos (ou atributos) bem definidos
- Tuplas em BD relacionais
- Semântica bem definida

_id	GRUPOS	GRUPOS	SERVICO	SERVICO	LOGRAD	NUMERO	BAIRRO	RPA	DATA_DE	SITUACA
1	7	ARBORIZ	8	PODA DE	AV BEIRA	00	TORRE	4	2016-07	ATENDIDA
2	7	ARBORIZ	8	PODA DE	AV MAUR	00	IPUTINGA	4	2016-07	ATENDIDA
3	7	ARBORIZ	16	VISTORIA	PRC PRO	00	JAQUEIRA	3	2016-07	CADAST
4	7	ARBORIZ	16	VISTORIA	RUA CAR	381	HIPODR	2	2016-07	CADAST
5	7	ARBORIZ	16	VISTORIA	RUA CAS	00	MADALENA	4	2016-07	CADAST
6	7	ARBORIZ	16	VISTORIA	RUA CELIA	00	MUSTAR	5	2016-07	CADAST
7	7	ARBORIZ	16	VISTORIA	RUA ES	255	GRACAS	3	2016-07	CADAST
8	7	ARBORIZ	16	VISTORIA	RUA FLO	0	SAO JOSE	1	2016-07	CADAST
9	7	ARBORIZ	16	VISTORIA	RUA FRA	378	SANTO A	1	2016-07	CADAST
10	7	ARBORIZ	16	VISTORIA	RUA GAR	275	CAMPIN	2	2016-07	CADAST
11	7	ARBORIZ	16	VISTORIA	RUA HA	51	CAMPO	2	2016-07	CADAST



Documentos vs. Entradas de BD: Consultas

- BD:
 - Busca nos campos do BD
 - Ex.: "Select * From Acidentes WHERE bairro='Iputinga' AND data='2016'"
- RI:
 - Procura em todo o texto pela ocorrência das palavras
 - Ex.: "Acidentes em Iputinga em 2016"
 - Casamento exato de palavras não é suficiente
 - Ex.: "uma batida de carro ocorreu na rua ..."



Várias Dimensões de RI

Content	Applications	Tasks			
Text	Web search	Ad hoc search			
Images	Vertical search	Filtering			
Video	Enterprise search	Classification			
Scanned docs	Desktop search	Question answering			
Audio	Forum search				
Music	P2P search	P2P search			
	Literature search				



- RI até recentemente restrita a bibliotecários
- A Web mudou isso
 - Autoria descentralizada e fácil acesso
 - Maior repositório de conhecimento na história da humanidade



Web Mudou a Busca por Informação

- Busca na Web é hoje a aplicação mais importante de RI
- Desafios:
 - Grande volume de dados: mais de 20 bilhões de páginas
 - Grande volume de consultas: Google 40 mil/s
- Desempenho e escalabilidade são cruciais!



Desafios para Coleta

- Dados distribuídos: mihões de sites ativos
- Dinamicidade: 80% desapareceu em 1 ano [Dasgupta et al., 2007]
- Documentos em diferentes formatos



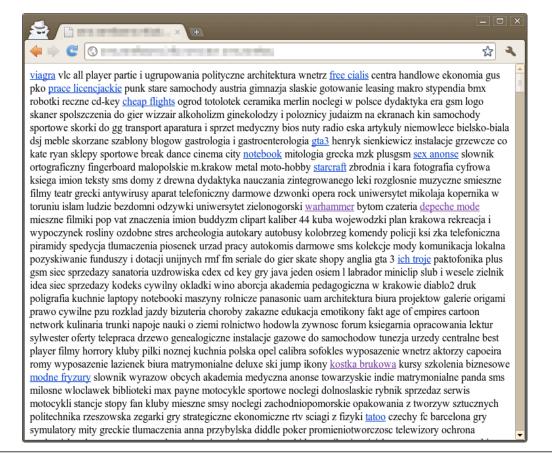






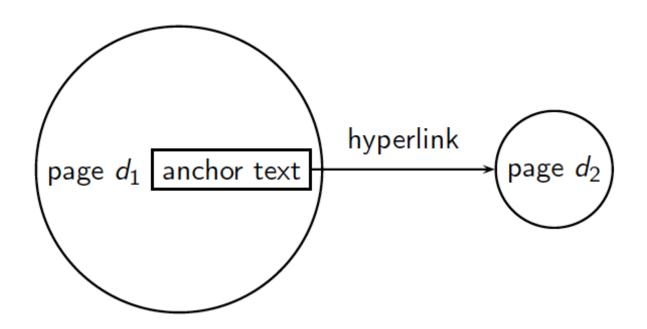
Outro Desafio: Spam

- Texto não informativo criado para dar visibilidade à página
- Afeta a eficiência e qualidade dos resultados





A Web é um Grafo Direcionado





RI e Engenhos de Busca

Information Retrieval

Relevance

-Effective ranking

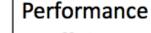
Evaluation

-Testing and measuring

Information needs

-User interaction

Search Engines



-Efficient search and indexing

Incorporating new data

-Coverage and freshness

Scalability

-Growing with data and users

Adaptability

-Tuning for applications

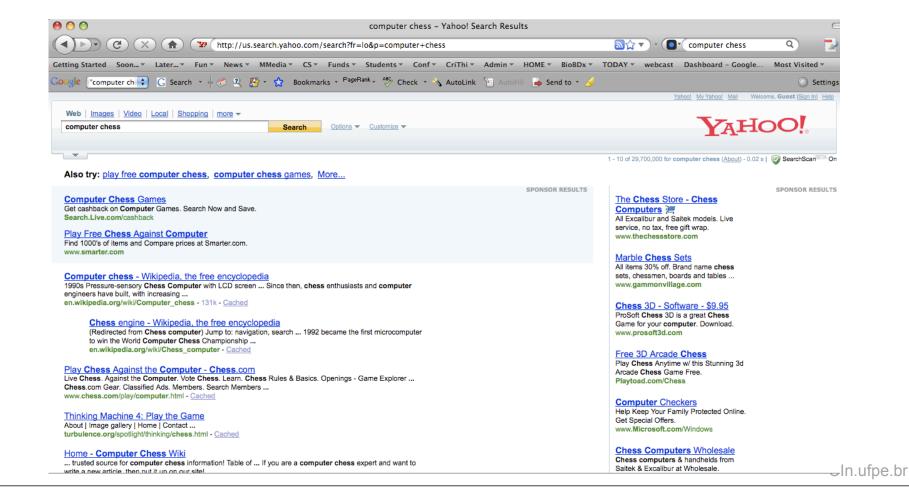
Specific problems

-e.g. Spam

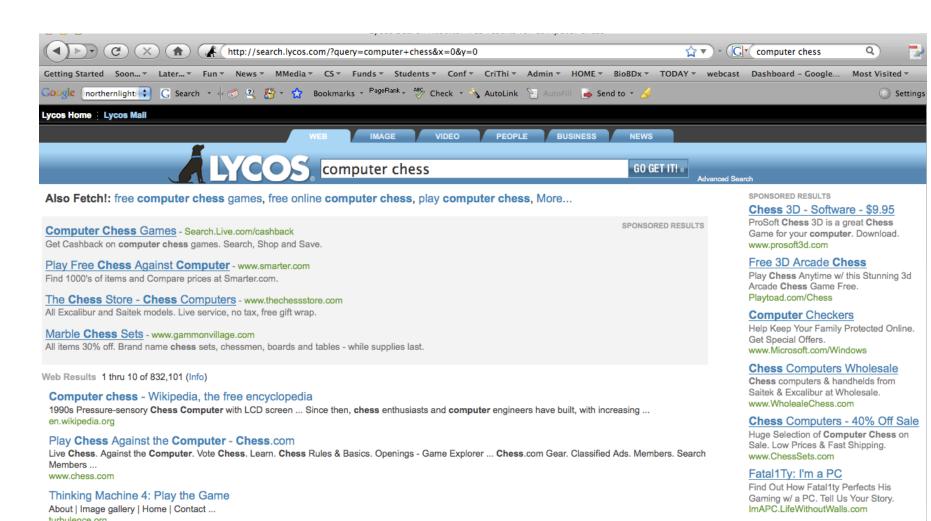




Iniciou em 1994 como diretório





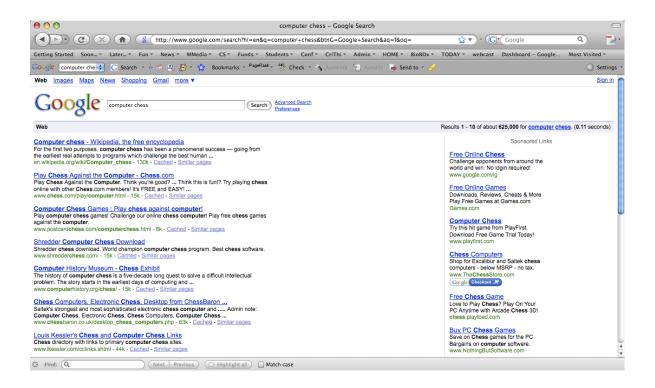








- Criado no começo dos anos 2000 por estudantes de doutorado
- Inovou com o algoritmo de PageRank





• Engenho de busca mais popular da China

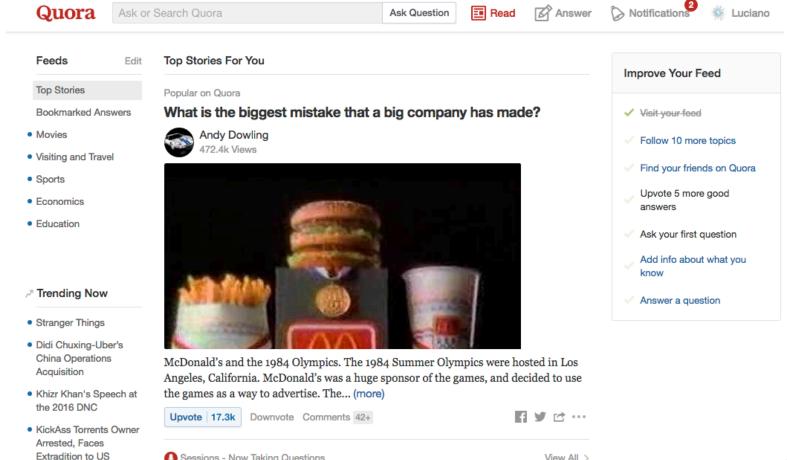




百度一下



Especializado em Q&A em linguagem natural





WolframAlpha

Busca sobre bases de conhecimento

